



MRI szegmentáció model-ensemble módszerrel Model Mavericks

Csató Erik - IRKR10
Egyedi Zsolt - I9D6EJ
Rimai Dániel - BR2BUJ

ACDC Challenge

Motiváció:

- A szív kamráinak és a szívizomfalak térfogatának ismeretében bizonyos betegségek diagnosztizálhatóak.
- Ezek a régiók mellkasi MRI képeken jól látszanak.

Cél:

- Olyan model-ensemble létrehozása, amely a lehető legpontosabban szegmentálja az input MRI felvételeket 4 osztály szerint

MRI szegmentációs módszerek

- Alapvetően U-net és az Ensemble módszer a domináns
 - Külön U-netek átlagolása
 - Diversity Promoting Ensemble
 - U-netek → Feature map, majd végső U-net → döntés (pl. triU-net)
- Dice értékek (1-DiceLoss): 0.86 - 0.96

#models (k)	Baseline		DiPE (ours)	
	Dice	IoU	Dice	IoU
2	0.9151	0.8886	0.9125	0.8856
3	0.9168	0.8903	0.9175	0.8911
4	0.9182	0.8920	0.9185	0.8922
5	0.9186	0.8923	0.9188	0.8927
6	0.9187	0.8924	0.9196	0.8936
7	0.9192	0.8931	0.9196	0.8935
8	0.9199	0.8938	0.9201	0.8940
All (9)	0.9199	0.8938	0.9199	0.8938

Diversity promoting Dice [1]

TABLE III
DICE SCORES FOR LV, RV AND MYO ON THE VALIDATION SETS

Method	Mean Dice LV ED	Mean Dice RV ED	Mean Dice MYO ED	Mean Dice LV ES	Mean Dice RV ES	Mean Dice MYO ES
*DCNN	0.822	0.761	0.510	0.719	0.652	0.601
DaDCNN-00	0.954	0.920	0.869	0.898	0.824	0.878
DaDCNN-01	0.955	0.916	0.868	0.902	0.845	0.880
DaDCNN-10	0.958	0.924	0.872	0.912	0.846	0.885
DaDCNN-11	0.959	0.924	0.873	0.918	0.849	0.884
*Unet-2	0.822	0.779	0.513	0.728	0.677	0.605
DaUnet-2	0.963	0.935	0.888	0.921	0.856	0.898
*Unet-1	0.825	0.778	0.509	0.732	0.684	0.605
DaUnet-1	0.959	0.921	0.877	0.915	0.839	0.890
*DeepLabv3+	0.914	0.824	0.746	0.825	0.686	0.771

Data-adapted Dilated CNN Dice [2]

ACDC dataset



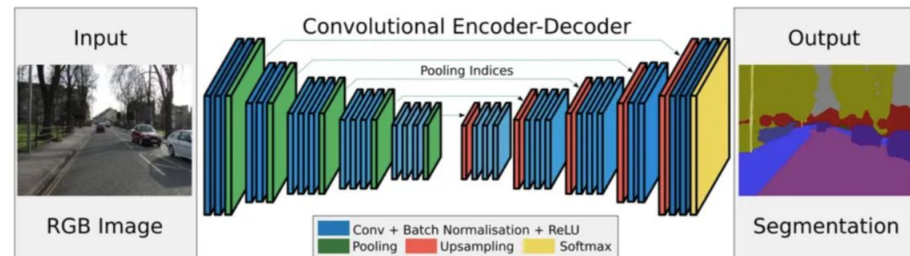
- Az adatbázis MRI képeket tartalmazó mappákból állt
- A harmadik dimenzió mentén az MRI felvételeket feldaraboltuk, hogy 2D képeket kapjunk
- Az összes kép dimenzióit egyenlő hosszúságúra "paddingeltük"
- Felosztottuk az adatbázist tanító - validáció - teszt halmazra
- Létrehoztunk egy pytorch dataloadert, amely pytorch-kompatibilis dataset-et hoz létre

Baseline

- Kezdetben ResNet majd SegNet alkalmazása
- DiceLoss használata
- MNIST teszt

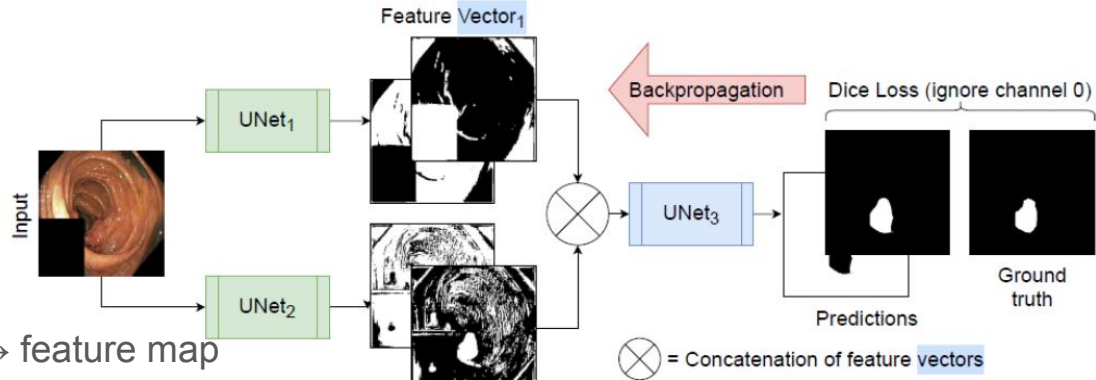
Baseline: Adam, $lr=1e-5$, $b=8$, $e=100$

MNIST: Adam, $lr=1e-3$, $b=16$, $e=100$




triU-net






- 3 U-net háló:
 - előtanított ResNet50 (UNet1) → feature map
 - előtanított DenseNet201 (UNet2) → feature map
 - saját konvolúciós háló (UNet3) → végleges szegmentáció
- Optimalizáció: AdamW, lr=0.001
- Loss: DiceLoss + TverskyLoss (egyenlő súllyal)
- Tanítása: 150 epoch, 2 batch, batch méret: 8 kép
- Eredmények: train Dice: 0.71, test Dice: 0.42



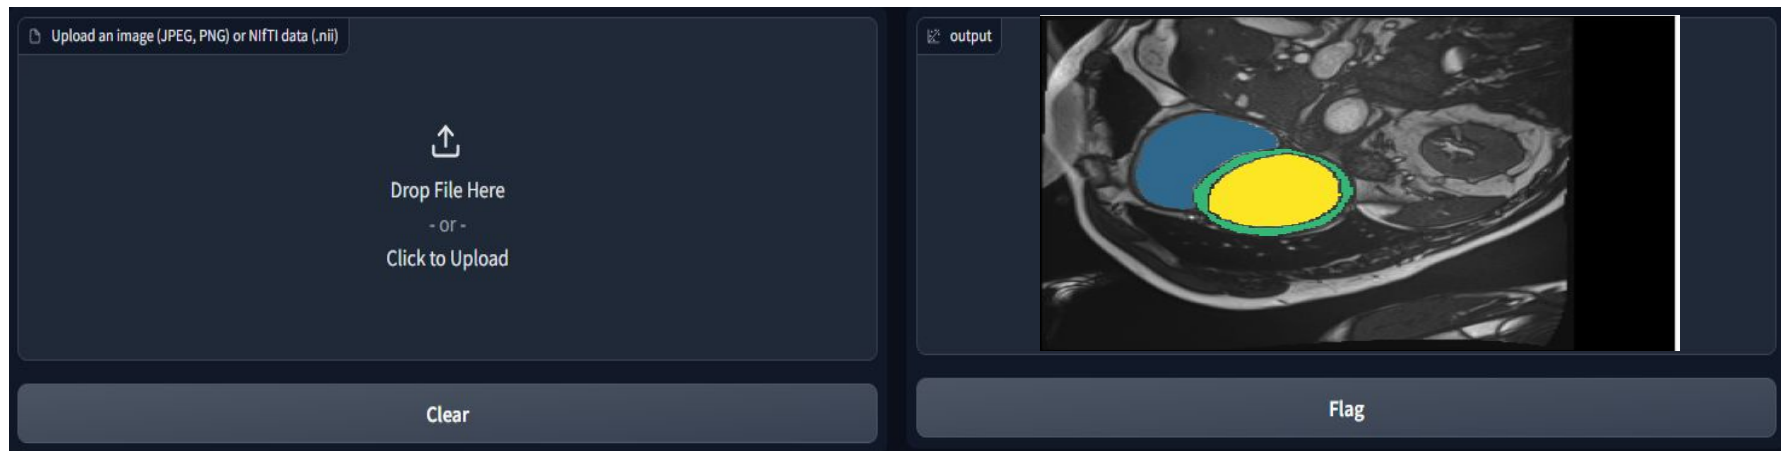
triUnet felépítése [3]



Kiértékelés




GUI



Summary

- Valószínűleg hibás “labellek” miatt nem sikerült túltanítanunk a modelleket
- Adatdúsítás



- Konténerizáció elkészült ➡ nagyobb adathalmazon, megfelelő címkézéssel és több erőforrással való tanítás segíthet a jobb eredmények elérésében

Köszönjük a figyelmet!



- [1] Diversity-Promoting Ensemble for Medical Image Segmentation - M-I. Georgescu, R. T. Ionescu, A-I. Miron
- [2] Cardiac MRI Segmentation With a Dilated CNN Incorporating Domain-Specific Constraints - G. Simantiris, G. Tziritas
- [3] DivergentNets: Medical Image Segmentation by Network Ensemble - V. Thambawita, S. A. Hicks, P. Halvorsen, M. A. Riegler
- [4] Benchmark Analysis of Representative Deep Neural Network Architectures - S. Bianco, R. Cadene, L. Celona, P. Napoletano
- [5] O. Bernard, A. Lalande, C. Zotti, F. Cervenansky, et al. "Deep Learning Techniques for Automatic MRI Cardiac Multi-structures Segmentation and Diagnosis: Is the Problem Solved ?"

